人形守门员：从位置条件化的任务–运动约束中学习

Junli Ren *,1,2 Junfeng Long*,2 Tao Huang2 Huayi Wang2 Zirui Wang2 Feiyu Jia2
Wentao Zhang2 Jingbo Wang2,† Ping Luo1,2,† Jiangmiao Pang2,†
1香港大学 2上海人工智能实验室 *同等贡献 †同等指导

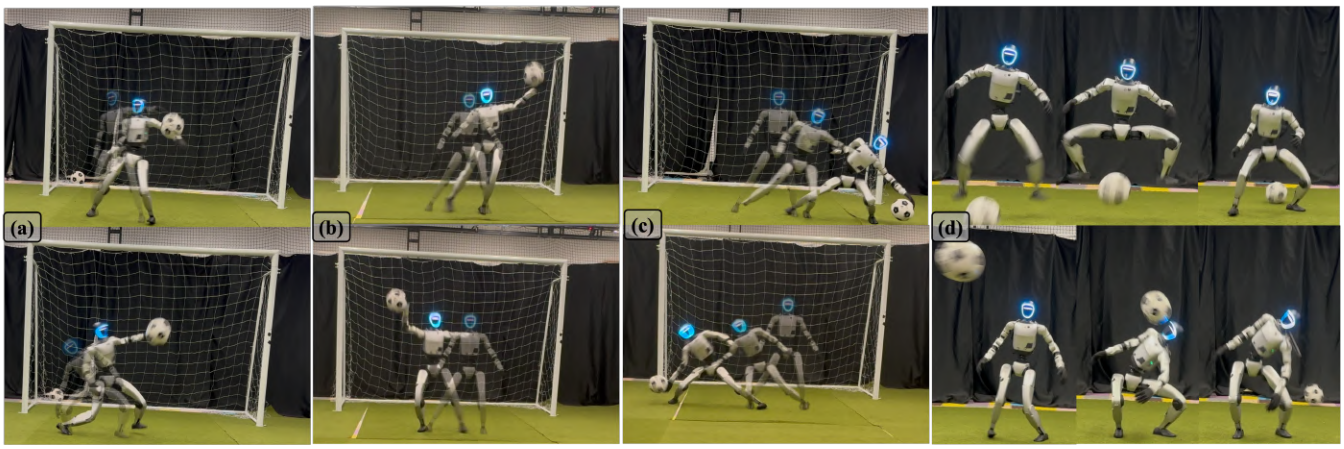


图 1：我们提出 Humanoid Goalkeeper（人形守门员），它能够在宽阔的工作范围内完成不同区域的守门任务（b、c），并能从任意姿态发起动作（a）。我们的策略使机器人能够以跳跃和蹲伏动作避开来球（d）。

摘要——我们提出了一个面向真实场景的人形机器人自主守门强化学习框架。已有工作已在四足平台上展示了类似能力，而人形守门引入了两个关键挑战：(1) 生成自然、类人的全身动作；(2) 在相同响应时间下覆盖更大的防守范围。与依赖单独遥操作或固定动作跟踪来实现全身控制的现有方法不同，我们的方法学习单一端到端强化学习策略，从而实现完全自主、高度动态且类人的机器人—物体交互。为此，我们通过对抗式方案，将多种以感知输入为条件的人体动作先验融入强化学习训练。我们通过真实世界实验验证了方法的有效性：人形机器人成功地对高速运动的足球完成了敏捷、自主且自然的拦截。除守门之外，我们还通过避球与抓球等任务展示了方法的泛化能力。我们的工作为机器人与运动物体之间的高度动态交互提供了实用且可扩展的解决方案，推动该领域走向更具适应性与类人化的机器人行为。更多细节（包括视频与实现代码）见我们的项目网站与 GitHub 仓库。

I. 引言

发展机器人足球能力天然要求感知、决策与敏捷运动控制的紧密集成，这使其成为评估运动智能的一个颇具吸引力的基准 [1–5]。在该领域中，守门是一个独特的子任务，包含许多尚未充分探索的挑战。与主要涉及下肢、且作用于缓慢或静止物体的带球 [6, 7] 或射门 [8, 9] 不同，守门要求对高度动态的刺激做出快速、全身的响应。推进机器人守门技术因而是迈向完全自主的实时物理智能的关键一步。

尽管机器人守门的研究热度日增，包括四足平台上动态技能的近期进展，现有系统在若干关键方面仍存在局限：局限于儿童尺寸的平台 [10]、依赖固定动作基元 [11]，以及仅在狭窄的拦截范围内工作。与此同时，强化学习（RL）[12, 13]、模仿驱动的动作先验 [14, 15] 以及人体动作恢复流程 [16–18] 的新进展，为解决这些局限开辟了新途径。结合高性能人形硬件与可扩展学习框架的出现，如今已有条件探索具备以下特性的守门员行为：(1) 表现出类人的全身交互动作；(2) 在极端时间约束下有效响应；以及 (3) 执行高度动态的动作，以覆盖广泛而多样的拦截区域。

本文提出 Humanoid Goalkeeper（人形守门员），一个用于人形机器人敏捷自主守门的、基于强化学习的框架。我们的方法学习单一端到端控制策略，通过对抗式训练方案将任务特定奖励与动作先验相结合，使策略同时优化任务性能与动作真实感。为应对大范围作业覆盖的挑战，我们以球的落点位置为条件来学习动作，从而有效地划分约束空间。为确保现实可行性，我们将感知噪声、轨迹估计与多模态传感纳入训练回路，以缩小仿真到现实的差距。通过在仿真和硬件上的大量评估，我们证明了该方法能够实现快速、反应灵敏且自然的

高速飞行球拦截。此外，我们表明所学策略能够泛化到避球、抓球等相关动态交互任务，凸显了该框架在更广泛的类人化、自适应人形机器人行为方面的潜力。

II. 相关工作

浮动基座上的动态物体交互。近期进展在动态物体与移动机器人之间的交互方面取得了令人瞩目的成果，在羽毛球 [19, 20]、乒乓球 [21–25]、基于移动机械臂的接球 [26, 27]、抛掷 [28] 以及足球 [1, 4, 6, 7, 29, 30] 等任务中均有显著应用。这些研究成功展示了机器人与动态物体之间毫秒级的交互，并高度集成了感知、规划与控制系统。此类方法在特定领域表现出色，例如连续动作执行 [21]、多智能体协同 [4, 31] 或专业级技能 [22]，但它们受限于狭窄的运动范围，或缺乏人形系统所需的动态全身敏捷性。在本工作中，我们通过开发一个能够覆盖大运动范围、同时执行敏捷且类人全身动作的人形守门员来弥补这些不足。

基于动作先验的全身控制。将模仿学习与强化学习框架相结合，已成为将人体动作技能迁移到人形机器人的主流方法。这些方法大多严格跟随固定时间相位的参考轨迹 [32–36]。它们通常局限于非交互任务，例如舞蹈或行走 [37, 38]，或受限于参考动作中预定义的交互时刻 [21, 39–43]。相比之下，对抗式动作先验（AMP）[14] 提供了一种替代思路：在不对时间对齐作严格约束的前提下融入专家数据。然而，这一潜力在真实世界人形任务中尚未被充分挖掘，当前框架仍局限于较简单的行走任务 [44, 45]。与此同时，在动画领域中，多动作先验合成已通过任务条件 token [46] 或子任务策略选择 [47] 得到探索。类似地，此前的四足守门员学会了针对不同的球目标区域，从一组预学习的底层技能中进行选择 [29]。在这些经验基础上，我们的方法针对不同的球目标区域分别训练任务奖励与动作判别器，并在每次试验中仅激活相应的约束。所提出的流程产生了一个单阶段、端到端、可部署于硬件的策略，在实现动态交互的同时保持与参考动作的相似性。

III. 方法

我们构建了能够自主、成功地执行守门技能，同时自适应地贴合人体动作先验的人形守门员。我们的方法（图 2）以一个端到端强化学习（RL）策略为核心，该策略生成高度动态且完全自主的守门行为。该策略直接作用于实时的球位置观测，这些观测同时充当所融合的人体动作先验的条件变量。这些先验通过对抗式训练方案融入 RL 过程，在不依赖预定义轨迹或严格动作跟踪的情况下，促进稳健而自然的动作生成。

我们的方法通过应对两个关键挑战推进了已有工作：(1) 我们提出一个统一框架，通过以观测为条件的对抗式训练同时约束任务成功与动作真实感，无需分离的优化阶段；(2) 我们在真实世界人形机器人上展示了硬件可行的高动态性能。

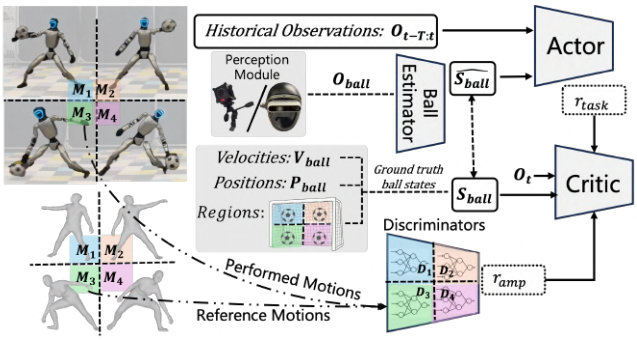


图 2：方法框架。我们使用端到端强化学习（RL）框架训练策略，并融入位置条件化的任务约束与运动约束。我们的方法既可使用机载相机，也可使用动作捕捉（MoCap）系统运行。

A. 基于强化学习的守门员训练

我们的学习系统旨在优化两个主要目标：(1) 任务成功与 (2) 与人类示范的动作相似度。本节详述我们基于强化学习、用于实现成功守门技能的优化过程。

1) 训练环境：我们使用标准 PPO 算法 [12] 训练策略，并在 IsaacGym 仿真器 [13] 中实现。该策略训练机器人阻止飞行中的球越过球门线。

观测空间包含所观测到的球的位置 $\boldsymbol{O_{ball}}$，并结合本体感知观测 $\boldsymbol{O_p}$。它们被用作 actor 的输入 $\boldsymbol{O}_t$，并带有长度为 T 的历史，以捕捉预测球运动轨迹所需的时间信息。

每个回合以向机器人发射一个球开始。训练环境被划分为 k 个区域，记作 $R = 0, 1, 2, \ldots,$ k，其中每个区域对应球门线上球可能到达的一个特定区域。区域在每个回合开始时确定，随后我们在该区域内采样一个随机的落点 $\boldsymbol{p}_{land}$，并据此设定球的速度以抵达目标。表 I 列出了训练期间使用的观测空间。所有与球相关的观测都在机器人局部坐标系中计算，便于直接使用机载感知进行部署。

表 I：actor 与 critic 网络的观测空间。

Observation	Actor	Critic
Ball position (in local frame) ($\mathbf{O}_{\text{ball}} \in \mathbb{R}^3$)	✓	✓
Base angular velocity ($\boldsymbol{\omega}_{\text{base}} \in \mathbb{R}^3$)	✓	✓
Projected gravity vector ($\mathbf{g}_{\text{base}} \in \mathbb{R}^3$)	✓	✓
Joint positions ($\mathbf{q} \in \mathbb{R}^{29}$)	✓	✓
Joint velocities ($\dot{\mathbf{q}} \in \mathbb{R}^{29}$)	✓	✓
Previous action ($\mathbf{a}_{\text{last}} \in \mathbb{R}^{29}$)	✓	✓
Base linear velocity ($\mathbf{v}_{\text{base}} \in \mathbb{R}^3$)	–	✓
End target region ($\mathcal{R} = 0, 1, 2, \ldots, k$)	–	✓
End effector target ($\mathbf{p}_{\text{target}} \in \mathbb{R}^3$)	–	✓
Ball velocity (in local frame) ($\mathbf{v}_{\text{ball}} \in \mathbb{R}^3$)	–	✓
Left hand position ($\mathbf{p}_{\text{hand}}^{\text{left}} \in \mathbb{R}^3$)	–	✓
Right hand position ($\mathbf{p}_{\text{hand}}^{\text{right}} \in \mathbb{R}^3$)	–	✓
Reach Distance ($\|\mathbf{p}_{\text{target}} - \mathbf{p}_{\text{hand}}^{(\mathcal{R})}\|$)	–	✓

2) 位置条件化的任务奖励：我们引入位置条件化的任务奖励 r_t，引导机器人通过跟踪动态目标将球挡在球门线之外。末端目标 $\boldsymbol{p}_{target}$ 的设计意图是促使机器人预测来球的落点，在球靠近时触球并将其击出，然后在球停止后保持静止姿态（图 3）。当球飞向机器人时，我们有：

$$\mathbf{p}_{\text{target}} = \mathbf{p}_{\text{land}} \cdot \mathbf{1}_{d_x > d_{th}} + \mathbf{p}_{\text{ball}} \cdot \mathbf{1}_{d_x \le d_{th}}, \quad (1)$$

其中 $1_{condition}$ 根据球与机器人之间的距离选择相应目标，d_x 表示球与球门线之间的距离，d_{th} 表示接近阈值。随后我们使用 sigmoid 函数定义如下平滑的、基于距离的奖励，以鼓励末端执行器（手）到达目标位置：

$$r_{\text{t}} = \{1 - \frac{1}{1 + \exp[-\sigma_{\text{keep}}(\|\mathbf{p}_{\text{target}} - \mathbf{p}_{\text{hand}}^{(\mathcal{R})}\| - d_{\text{keep}})]}\} \times (1 + \nu^{(\mathcal{R})}), \quad (2)$$

其中 σ_{keep} 是缩放因子，d_{keep} 是判定末端执行器何时足够接近球的接球距离阈值。奖励 r_t 通过计算所选手与末端目标之间的距离 $\|\boldsymbol{p}_{target} - \boldsymbol{p}_{hand}{}^{(R)}\|$ 而取决于落点区域 R。例如，若球飞向左侧区域，机器人应使用左手拦截，右侧区域同理。

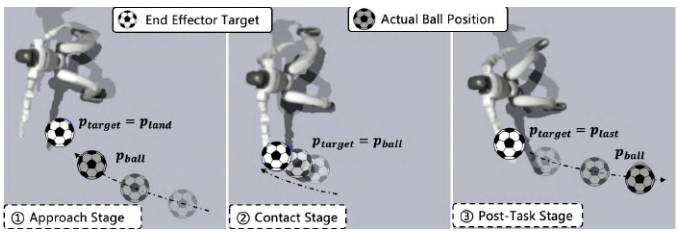


图 3：该设计确保当球离机器人较远时，交互基于预测落点；而对于较近的球，目标位置即球的真实位置，从而能在机器人附近实现更精确的处理。

我们引入位置条件化的动力学调制项 $\nu^{(R)}$，以鼓励诸如横移或跳跃等全身动作，具体取决于区域 R：

$$\nu^{(\mathcal{R})} = \nu_y \cdot \mathbf{1}_{\mathcal{R}\in\text{right}} + (-\nu_y) \cdot \mathbf{1}_{\mathcal{R}\in\text{left}} + \nu_z \cdot \mathbf{1}_{\mathcal{R}\in\text{up}}, \quad (3)$$

$\nu^{(R)}$ 促进一致的全身动作，在拦截过程中支撑协调的末端执行器运动。

除位置条件化奖励 r_t 之外，我们还引入额外的奖励项以施加动作约束并促进硬件可行的行为。完整的奖励公式见附录。

3) 任务后稳定性：我们将回合长度设为 3 秒，远长于球的飞行时间（通常为 0.4– 秒），以便留出任务后稳定化的时间。为鼓励机器人在球通过后保持规整姿态，我们引入任务后奖励项，以促进平衡以及从高动态守门动作中恢复。这些奖励一般定义为：

$$r_{\text{post}} = \exp\left(-\sigma_{\text{stable}} \cdot \|\mathbf{Err}_{\text{stable}}\|\right) \cdot \mathbf{1}_{\text{ball stopped}}, \quad (4)$$

其中 Err_{stable} 表示关键稳定性相关量——如基座高度、角速度与姿态——相对其标称值的偏差。指示函数 $1_{ball\ stopped}$ 仅在球已被守住或飞至机器人身后时才激活该奖励。此外，我们将一部分环境重置为从其他正在进行的环境采样得到的关节位置，而非默认关节配置。这迫使机器人在上一次守门动作进行中途开始新的试验，而不是从标称重置状态开始。除了促进稳定性之外，我们发现该策略对于学习连续守门行为很有效，因为机器人无需回到默认姿态即可发起新的回合。

B. 带动作约束的优化

我们引入位置条件化的对抗式动作先验（AMP）奖励，在训练期间施加动作约束，鼓励机器人根据球的落点区域展现恰当的运动风格（见图 2）。受 [29] 的启发——该工作研究了四足机器人的区域特定守门——我们将模仿学习融入强化学习，以促进区域一致的行为。这些动作约束源自基于人类示范构建的任务特定动作库。

1) 参考动作整理：我们首先利用现有流程（GVHMR [16]）从自录的 RGB 视频中提取人形动作（图 4）。随后，我们将提取的动作重定向到 Unitree G1 机器人，并将得到的关节位置序列 q_t 存储到区域特定的动作参考缓冲区中。

2) 带动作约束的优化：动作约束通过对抗式动作先验（AMP）奖励 [14] 实现，它鼓励机器人在拦截过程中展现区域一致的运动风格。为此，我们通过为每个区域 R 关联一个专用的参考动作槽以及相应的判别器 $D^{(R)}$，定义位置条件化的 AMP 奖励。每个判别器被训练用于区分来自

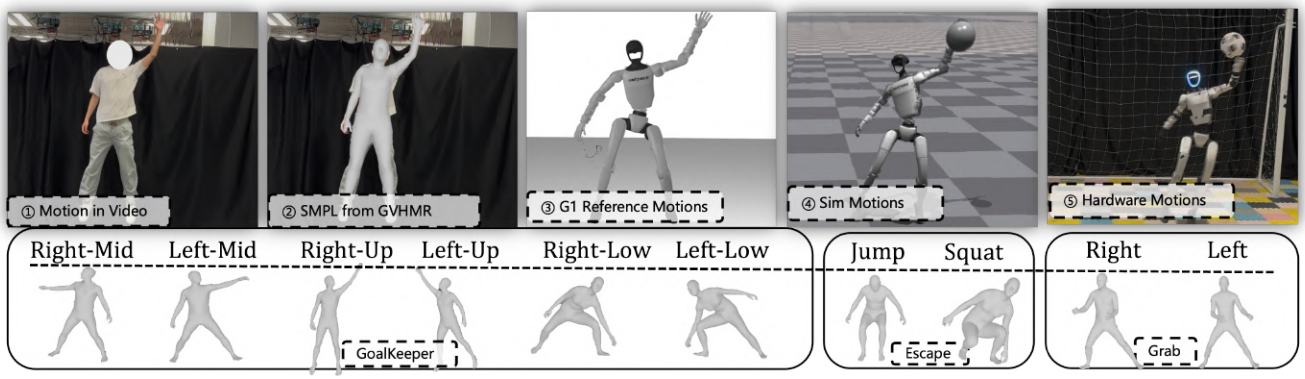


图 4：动作整理与公式化流程，展示了从人类视频到机器人执行动作的过程。

参考动作的状态转移与由策略生成的状态转移。$D^{(R)}$ 的训练目标为：

$$\arg\min_{D^{(\mathcal{R})}} \mathbb{E}_{(q_t,q_{t+1})\sim d_M^{(\mathcal{R})}}\left[(D^{(\mathcal{R})}(q_t,q_{t+1})-1)^2\right] + \mathbb{E}_{(q_t,q_{t+1})\sim d_\pi^{(\mathcal{R})}}\left[(D^{(\mathcal{R})}(q_t,q_{t+1})+1)^2\right], \quad (5)$$

其中 ${d_M}^{(R)}$ 与 ${d_\pi}^{(R)}$ 分别表示在给定区域 R 条件下，来自专家参考动作与来自策略的关节位置转移 (q_t, q_{t+1}) 的分布。

鉴于本任务对精度的高要求，我们更柔和地施加动作约束，以避免与任务特定目标发生冲突。与原始 AMP 公式——直接为执行动作打分并奖励那些与参考分布高度匹配的动作——不同，我们在每个执行动作周围生成高斯采样，并且只奖励判别器得分最高的那一个。这鼓励与参考动作分布平滑对齐，使策略能够为相近动作获得相似奖励，同时让任务目标决定精确的执行方式。AMP 奖励计算如下：

$$r_{\text{amp}} = \max_{j\in\{1,\dots,N\}}\left\{\max\left[0, 1-0.25\left(D(\tilde{q}_t^{(j)},\tilde{q}_{t+1}^{(j)})-1\right)^2\right]\right\}, \quad (6)$$

其中每个 $(\tilde{q}_t{}^{(j)}, \tilde{q}_{t+1}{}^{(j)})$ 均从以实际执行的转移 (q_t, q_{t+1}) 为中心的高斯分布中采样。

C. 对齐仿真到现实的感知

获得可部署于硬件的球感知能力、并弥合仿真到现实的差距，是动态物体交互任务中的关键挑战。在本工作中，机器人接收相对于其躯干坐标系的球位置，用观测向量 $\boldsymbol{O_{ball}} \in R^3$ 表示。我们实现了两套基于硬件的感知系统来获取球位置 $\boldsymbol{O_{ball}}$：1) 动作捕捉（MoCap）系统，在机器人头部与球上放置标记，其中 $\boldsymbol{O_{ball}}$ 由 MoCap 系统报告的两者相对位置计算得到；2) 安装在机器人头部、带红外（IR）滤光片的深度相机（Intel RealSense D435i）[4]，它能够检测高反射率的球，并直接从相机感知流程中估计 $\boldsymbol{O_{ball}}$。尽管两套系统都能提供相当准确的球位置估计，但由于标定误差与感知局限——例如 MoCap 系统中的遮挡以及基于相机的系统中的视场约束——仍存在性能差距。为缓解这些问题，我们在策略中引入球位置估计器，并引入训练期噪声，以提升在两种感知模态下的鲁棒性。

1) 球估计器：我们将球估计器集成到训练回路中，它能够有效识别区域（用于任务与运动条件），并准确预测球的位置与运动轨迹（图 2），充分利用历史观测。位置估计器使用均方误差（MSE）损失训练，以最小化球位置预测误差；区域估计器则使用交叉熵损失训练，以分类球可能落到的正确区域。

2) 训练噪声：为模拟真实世界的感知不确定性，我们在训练期间向球观测 $\boldsymbol{O_{ball}}$ 引入噪声。具体而言，我们施加：1) 位置噪声——最多 $5cm$ 的随机扰动，即球 $10cm$ 半径的一半——以模拟典型的传感误差；2) 随机丢失——$\boldsymbol{O_{ball}}$ 在飞行 $0.4s$ 后被偶尔置零，以模拟球接近时硬件感知中遇到的遮挡或超出视场的情形。此外，一旦球停止飞行（例如被拦截或落地后），我们将 $\boldsymbol{O_{ball}} = 0$，以反映不再进行跟踪。随后如第 III-A.3 节所述，鼓励机器人保持其最终姿态。

IV. 评估

我们开展了一系列实验来全面评估所提方法，聚焦以下目标：1) 验证本方法在掌握人形守门技能方面的有效性（从成功率与覆盖范围角度）；2) 评估机器人执行动作与专家示范之间的相似度；3) 评估所提出的位置条件化学习方案相较于不做区域划分的基线所带来的收益。为此，我们设计了反映任务性能、动作保真度与动作平滑性的评估指标：

表 II：仿真实验结果。

方法	任务		运动			平滑性	
	$E_{\text{succ}}\uparrow$	$E_{\text{ee task}}\downarrow$	$E_{\text{match}(\mathcal{R})}\uparrow$	$E_{\text{pos}(min)}\downarrow$	$E_{\text{pos}(\mathcal{R})}\downarrow$	$E_{\text{dof acc}}\downarrow$	$E_{\text{smth}}\downarrow$
Ablation Motion / Task Constraints							
w.o. Task Constraints	9.44±4.82	0.55±0.018	64.33±5.37	**0.76**±0.012	**0.98**±0.060	**14.26**±0.275	**0.030**±0.001
w.o. Motion Constraints	31.69±1.18	0.98±0.172	8.83±4.50	1.73±0.018	2.03±0.025	62.23±4.368	0.151±0.015
Humanoid Goalkeeper (ours)	**80.92**±1.72	**0.12**±0.004	**67.84**±1.49	1.24±0.017	1.31±0.021	22.80±0.404	0.042±0.001
Ablation Position Division							
w.o. AMP Division	76.11±2.19	0.14±0.010	25.73±5.03	1.39±0.007	1.51±0.015	23.18±0.326	0.043±0.000
w.o. Task Division	62.08±4.30	0.14±0.005	39.18±3.60	1.62±0.007	1.84±0.030	28.69±0.329	0.054±0.000
w.o. Division	64.83±5.07	0.14±0.004	19.09±5.39	1.62±0.023	1.87±0.057	28.56±0.450	0.052±0.001
Humanoid Goalkeeper (ours)	**80.92**±1.72	**0.12**±0.004	**67.84**±1.49	**1.24**±0.017	**1.31**±0.021	**22.80**±0.404	**0.042**±0.001
Evaluation Settings							
Speed-Easy ($0.7s \sim 1.0s$)	80.95±4.21	0.12±0.012	50.88±3.28	1.26±0.008	1.37±0.021	23.20±0.432	0.042±0.001
Range-Easy ($\pm 1.0m$)	**84.64**±2.75	0.13±0.011	63.16±4.47	1.26±0.007	1.32±0.012	22.23±0.244	0.041±0.000
Speed-Hard ($0.4s \sim 0.7s$)	64.25±7.23	0.13±0.009	**70.47**±3.53	1.26±0.013	**1.29**±0.015	**21.85**±0.324	**0.041**±0.000
Range-Hard ($\pm 2.0m$)	63.91±2.29	0.15±0.007	63.45±7.92	1.26±0.009	1.33±0.012	24.42±0.449	0.044±0.001
Default ($0.5s \sim 1.0s$, $\pm 1.5m$)	80.92±1.72	**0.12**±0.004	67.84±1.49	**1.24**±0.017	1.31±0.021	22.80±0.404	0.042±0.001

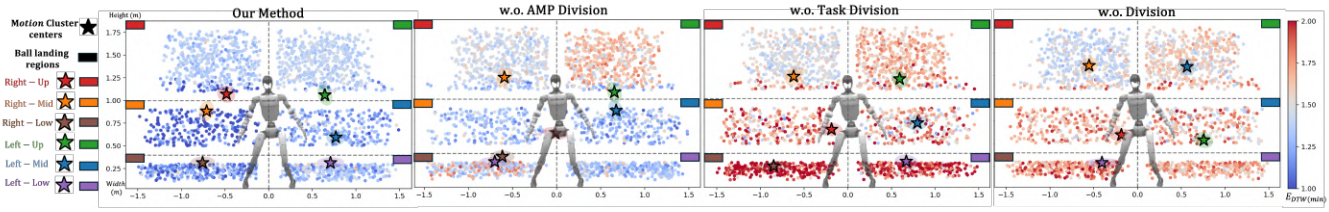


图 5：每个散点代表一次试验，其位置对应该次试验的球目标。点的颜色梯度表示每次试验的 $E_{pos(min)}$。五角星代表具有相同匹配区域（E_{pos} 最小的区域）的试验的聚类中心。一个学习良好的位置条件化策略，应当在其聚类中心与各自的球目标区域之间呈现出清晰的对应关系

$E_{succ}\uparrow$ 成功封堵球的比率。

$E_{\text{ee task}}\downarrow$ 一次试验中末端执行器（手）与球之间的最近距离。

$E_{pos(R)}\downarrow$ 相对于来自球目标区域 R 的专家动作的姿态误差（经动态时间规整 DTW [48] 处理）。

$E_{pos(min)}\downarrow$ 在所有区域中，执行动作与专家动作之间的最低姿态误差。

$E_{match(R)}\uparrow$ 最匹配的动作是否与球目标区域 R 对齐。

$E_{dof\,acc}\downarrow$ 关节加速度：$|\ddot{q}_t - \ddot{q}_{t-1}| / \Delta t$。

$E_{smth}\downarrow$ 动作平滑性：$|a_t - 2a_{t-1} + a_{t-2}|$。

在仿真中的训练与评估过程中，球门区域被划分为六个预定义的球落点区域，相应的专家动作可视化于图 4，区域边界示于图 5。我们对每个区域进行 500 次仿真试验和 5 次硬件试验。球的飞行时长范围为 0.5 s 到 1.0 s，飞行距离从 3.0 m 到 5.0 m 不等。硬件评估中使用的球门对应五人制足球比赛的标准尺寸，宽度为 3.0 m（两门柱之间），高度为 2.0 m。

A. 仿真结果

表 II 总结了仿真实验的主要数值结果。所提方法取得了最高的任务成功率，同时在与所有基线相比也展现出更优的动作相似度。这些结果支持我们的核心假设：将任务约束与恰当的运动约束对齐能够带来更好的整体性能。值得注意的是，去掉 AMP 区域划分（w.o. AMP Division）的变体——它缺乏显式的动作分段，但保留了基于区域的任务约束——取得了中等偏上的成功率与动作指标。这一结果表明，正确的任务条件化在一定程度上能够引导动作选择。然而，其性能仍落后于完整方法，凸显了显式动作对应关系对于实现高质量、任务对齐行为的重要性。

在宽度 (±1.5 m)、高度 1.8 m 的默认守门范围下，所提方法取得了显著高的成功率——尽管其作业区域是机器人守门文献中报道的最宽区域之一。为进一步评估鲁棒性，我们在变化的球速与扩大的防守区域下评估该方法。如预期所料，结果表明随着任务难度增加性能逐渐下降，这验证了方法的可扩展性，同时揭示了其在更具挑战性条件下的当前局限。

平滑性指标是评估动作与任务约束之间的对齐在多大程度上转化为自然机器人行为的一个有用指标。我们的结果支持这一联系：由准确专家动作引导的策略取得了更好的平滑性。有趣的是，没有显式任务约束的基线——仅依赖 AMP 与正则化奖励——却取得了最佳的

表 III：硬件实验结果。

方法	右-低			右-中			右-高		
	$E_{\text{succ}}\uparrow$	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}\downarrow$	E_{succ}	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}$	E_{succ}	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}$
Humanoid Goalkeeper (camera)	1/5	1.67	**21.79**	3/5	1.46	21.30	**3/5**	1.56	32.99
w.o. AMP Division (mocap)	0/5	**1.43**	31.02	3/5	1.36	**20.62**	0/5	1.47	31.33
w.o. Division (mocap)	1/5	1.66	36.13	0/5	1.46	31.09	2/5	1.57	34.47
Humanoid Goalkeeper (mocap)	**5/5**	1.49	33.34	**4/5**	**1.28**	24.56	1/5	**1.43**	**29.43**
方法	左-低			左-中			左-高		
	$E_{\text{succ}}\uparrow$	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}\downarrow$	E_{succ}	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}$	E_{succ}	$E_{\text{pos}(min)}$	$E_{\text{dof acc}}$
Humanoid Goalkeeper (camera)	1/5	1.70	**24.04**	3/5	1.53	21.71	3/5	1.58	28.12
w.o. AMP Division (mocap)	5/5	**1.48**	35.25	2/5	1.54	**18.60**	3/5	1.47	27.68
w.o. Division (mocap)	3/5	1.48	29.88	3/5	**1.43**	23.77	3/5	1.68	38.87
Humanoid Goalkeeper (mocap)	5/5	1.68	**28.76**	**3/5**	1.44	22.08	3/5	**1.40**	**27.16**

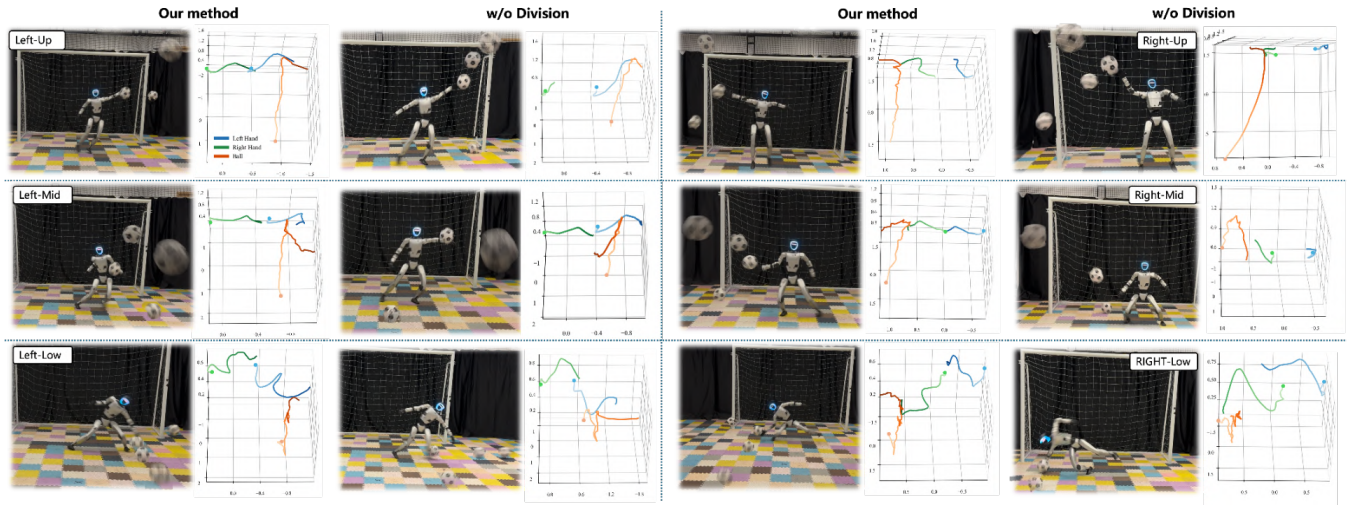


图 6：我们可视化了球的三维轨迹，以及每个区域中一次试验的左手与右手轨迹，并将所提方法与不做区域划分的基线的性能进行了对比。

平滑性表现。这表明，在缺乏基于区域的目标时，机器人可能会优先考虑通用的动作规整性而非任务有效性，从而产生更平滑但目的性更弱的行为。

图 5 提供了基于区域的运动行为可视化，以验证我们的方法。在每个子图中，五角星代表与特定专家动作最匹配的机器人执行动作的聚类中心。结果表明，我们的方法能够有效学习区域条件化的动作，每个区域都涌现出清晰且一致的聚类。相比之下，基线方法倾向于在不同区域之间混淆动作，导致行为一致性较差、关节位置误差更高。这凸显了我们基于区域条件化的策略学习在保持与任务语义一致的动作结构方面的有效性。

B. 区域特定的硬件评估

表 III 展示了守门任务上区域特定的硬件评估结果。所提方法取得了 21/30 的总成功率，大多数失败案例集中在上部区域。这些上部区域要求末端执行器与球轨迹之间更严格的对齐，以及大范围的全身动作——相比下部与两侧区域挑战更大。

尽管存在这些挑战，在所有对比方法中，我们的方法表现出最小的仿真到现实性能下降。相比之下，不做区域划分的基线倾向于过拟合到球门的一侧，而在其他区域表现不佳。具体而言，它们在左侧的表现始终优于右侧，表明其缺乏覆盖整个球门区域的泛化能力。我们在图 6 中进一步说明这一现象，该图可视化了球轨迹与末端执行器运动（通过 MoCap 记录）。可视化显示，对于飞向右侧区域的球，由不做区域划分的基线控制的机器人未能提前启动横向跨步，导致因响应窗口过短而扑救失败。相反，我们的方法从一开始就准确地将末端执行器引导至合适的区域，从而实现成功拦截。这凸显了区域感知的动作学习在实现覆盖整个球门的均衡、稳健性能方面的有效性。

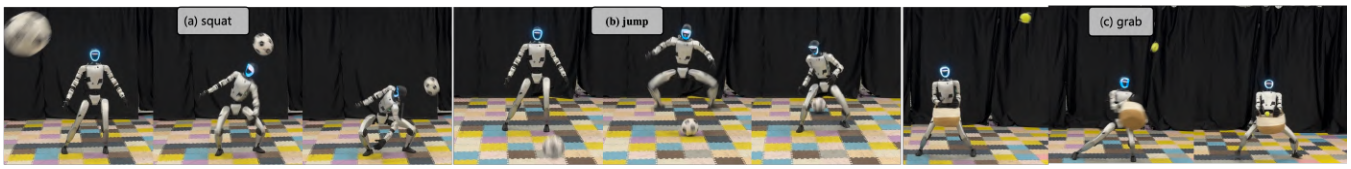


图 7：我们展示了扩展任务的泛化能力，包括抓球与避球。

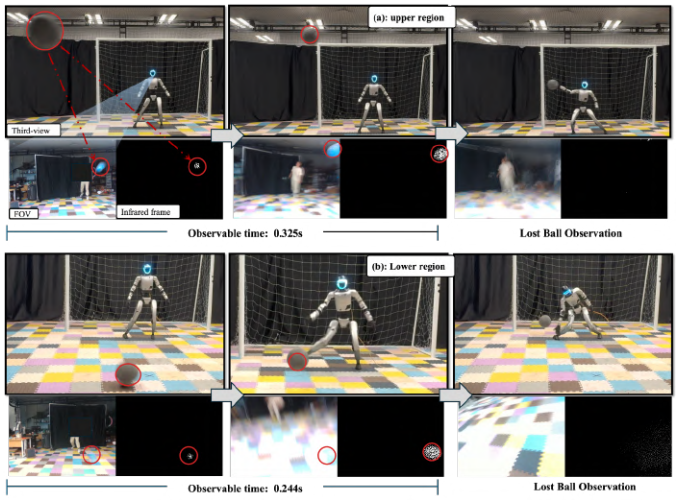


图 8：机载相机感知的第一视角示意图。

C. 基于相机感知的性能

基于相机感知的性能降至 14/30 次成功试验，低于 MoCap 方案。主要限制来自相机较窄的视场（FoV），这缩短了球的可观测时间窗口。如图 8 所示，高反射率的球在较远处即可通过相机的红外通道被轻松检测到。然而，当球接近机器人时，它会迅速从视野中消失，使下部区域的可观测时间不足 0.3 秒。这种可见性受限导致缺乏一致的球跟踪，从而造成成功率下降。

尽管存在视场约束，基于相机的系统在上部区域仍取得了较高的成功率，因为在这些区域球保持可见的时间更长。这一结果表明，在仅依赖机载感知时，所提方法具有良好的鲁棒性与适应性。此外，感知约束自然地抑制了大幅度的突变动作（例如横向跳跃），从而带来更平滑的行为，这体现在相比基于 MoCap 的评估，$E_{dof\,acc}$ 得分有所改善。

D. 连续守门

图 9 表明，所提流程使机器人能够连续执行守门技能，而无需在两次试验之间手动重置到默认状态。这由来自球门两侧的两次连续成功拦截所证明。如快照上的时间戳所示，机器人直接从第一次试验的终止姿态转入第二次试验的起始动作，而无需

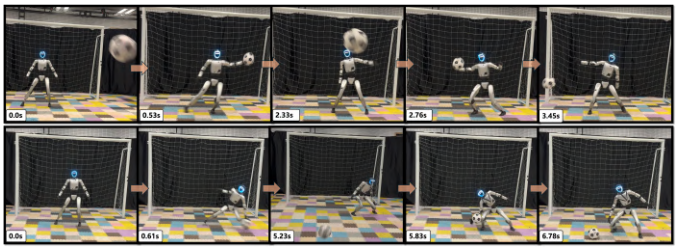


图 9：机器人在不重置到默认姿态的情况下执行连续守门的快照。

进入恢复阶段。这一能力凸显了我们的方法在需要不间断、类比赛行为的真实世界场景中的潜力。

E. 泛化任务

以守门任务为中心，我们提出一个有效框架，使机器人能够借助所学动作先验，与动态物体进行全身交互。为展示该框架在守门之外的泛化能力，我们将其扩展到两个同样需要高动态响应的额外任务：(1) 躲避飞来的球，以及 (2) 使用软袋抓取运动中的球。

这些动作使用与守门相同的位置条件化方法开发。具体而言，我们依据球的空间特征划分输入空间：高位置与低位置分别对应跳跃与蹲伏避球；左位置与右位置分别对应向左跨步与向右跨步的抓球。我们表明这种基于区域的划分能够确保在不同条件下选择合适的动作。表 IV 给出了我们的方法在这些任务上的定量结果。

表 IV：避球任务评估。

任务			
Jump Escape	3/5	1.49	46.79
Squat Escape	5/5	1.12	16.19
Grab Tennis	1/5	0.99	18.25

在避球任务中，机器人取得了高成功率，并高度复现了专家动作（图 7），验证了我们泛化能力的有效性。机器人能够在 0.5 秒内对来球做出反应并执行成功的闪避动作。同时，从静止站姿起跳是一种高度动态的动作，会产生显著的关节加速度。抓球任务的成功率较低，原因在于训练中缺少

对袋子的建模。在仿真中，成功抓取被定义为球落在机器人双手之间，这隐含假设了袋口始终张开且袋体刚性。然而在真实世界试验中，软袋袋口的可变形性与多变朝向频繁违背这一假设，如图 10 所示。尽管存在这些困难，我们观察到机器人仍能可靠地朝球的预测落点移动。



图 10：袋子的不可控特性导致抓球成功率偏低。

V. 讨论

我们开发了一个人形机器人守门员，它能够执行敏捷、类人的动作来拦截飞行的球，并能完成诸如以跳跃和蹲伏动作避球等任务。我们的结果表明，基于任务观测显式地对齐任务约束与动作约束，能够显著提升动作质量与任务完成度。大量实验评估以及替代的感知模块，为我们的方法有效性提供了有力证据。

然而，作为首个类人水平的自主守门员，在达到职业级守门表现之前仍有改进空间。具体而言：

(1) 缺乏全局观测与高层规划模块，限制了我们的框架在比赛级别执行连续守门动作的能力。

(2) 感知模块需要进一步完善，以便在真实世界场景中对复杂情况做出恰当反应。目前，机器人会响应其视野内检测到的任何球，即使该球并非飞向球门，这在真实比赛中是不合理的。

未来工作可以聚焦于加入高层规划器以实现连续守门动作，例如在每次试验后重新调整站位。此外，通过引入主动感知能力来克服相机视场（FOV）限制、并消除对固定动作捕捉系统的依赖，对于提升真实环境中的鲁棒性与灵活性至关重要。进一步地，为提升机器人当前的动作能力，我们认为训练它用手抓球、而非仅仅将球击出，将是一个颇具吸引力的挑战，也是人形—物体交互技能的有价值示范。

VI. 致谢

本工作是在作者于上海人工智能实验室具身智能中心实习期间完成的。我们感谢上海人工智能实验室智能光电与电子中心对动作捕捉系统的支持以及提供实验场地。我们特别感谢 Yuman Gao 分享其基于机载相机的飞行球拦截代码库，该代码库改编自他此前的工作 [4]。

REFERENCES

[1] T. Haarnoja et al., “Learning agile soccer skills for a bipedal robot with deep reinforcement learning,” *Science Robotics*, 2023.
[2] M. Beukman, B. Ingram, G. N. Tasse, B. Rosman, and P. Ranchod, “Robocupgym: A challenging continuous control benchmark in robocup,” *ArXiv*, 2024.
[3] D. Tirumala et al., “Learning robot soccer from egocentric vision with deep reinforcement learning,” in *Conference on Robot Learning*, 2024.
[4] “Toward real-world cooperative and competitive soccer with quadrupedal robot teams,” *Arxiv*, 2025.
[5] G. I. Fernandez, R. Hou, A. Xu, C. Togashi, and D. W. Hong, “Clap: Clustering to localize across n possibilities, a simple, robust geometric approach in the presence of symmetries,” *ArXiv*, 2025.
[6] Y. Ji, G. Margolis, and P. Agrawal, “Dribblebot: Dynamic legged manipulation in the wild,” in *International Conference on Robotics and Automation (ICRA)*, 2023.
[7] Z. Wang, J. Zhou, and Q. Wu, “Dribble master: Learning agile humanoid dribbling through legged locomotion,” *Arxiv*, 2025.
[8] Y. Ji et al., “Hierarchical reinforcement learning for precise soccer shooting skills using a quadrupedal robot,” 2022.
[9] D. Marew, N. Perera, S. Yu, S. Roelker, and D. Kim, “A biomechanics-inspired approach to soccer kicking for humanoid robots,” in *IEEE-RAS 23rd International Conference on Humanoid Robots (Humanoids)*, 2024.
[10] B. Robotics, *Booster t1: Humanoid robot*, Accessed: 2025-09-15, 2025.
[11] Y. Ze et al., “Twist: Teleoperated whole-body imitation system,” *ArXiv*, 2025.
[12] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *Arxiv*, 2017.
[13] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, “Learning to walk in minutes using massively parallel deep reinforcement learning,” in *Conference on Robot Learning*, 2022.
[14] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, and A. Kanazawa, “Amp: Adversarial motion priors for stylized physics-based character control,” *ACM Transactions on Graphics (ToG)*, 2021.
[15] A. Tang et al., “Humanmimic: Learning natural locomotion and transitions for humanoid robot via wasserstein adversarial imitation,” in *International Conference on Robotics and Automation (ICRA)*, 2024.
[16] Z. Shen et al., “World-grounded human motion recovery via gravity-view coordinates,” in *SIGGRAPH Asia 2024 Conference Papers*, 2024.
[17] Y. Zhang et al., “Humanmm: Global human motion recovery from multi-shot videos,” in *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
[18] Z. Shen et al., “World-grounded human motion recovery via gravity-view coordinates,” 2024.
[19] Y. Ma, A. Cramariuc, F. Farshidian, and M. Hutter, “Learning coordinated badminton skills for legged manipulators,” *Science Robotics*, 2025.
[20] H. Wang et al., “Integrating learning-based manipulation and physics-based locomotion for whole-body badminton robot control,” *International Conference on Robotics and Automation (ICRA)*, 2025.

[21] Z. Su et al., "Hitter: A humanoid table tennis robot via hierarchical planning and learning," *Arxiv*, 2025.

[22] D. B. D'Ambrosio et al., "Achieving human level competitive robot table tennis," in *International Conference on Robotics and Automation (ICRA)*, 2025.

[23] K. M. Lee et al., "Learning diverse robot striking motions with diffusion models and kinematically constrained gradient guidance," *International Conference on Robotics and Automation (ICRA)*, 2025.

[24] M. Hu et al., "Towards versatile humanoid table tennis: Unified reinforcement learning with prediction augmentation," *ArXiv*, 2025.

[25] D. Nguyen, Z. Zaidi, K. Karol, J. Hodgins, and Z. Xie, "Whole body model predictive control for spin-aware quadrupedal table tennis," *ArXiv*, 2025.

[26] Y. Zhang, T. Liang, Z. Chen, Y. Ze, and H. Xu, "Catch it! learning to catch in flight with mobile dexterous hands," in *International Conference on Robotics and Automation (ICRA)*, 2025.

[27] S. Abeyruwan et al., "Agile catching with whole-body mpc and blackbox policy learning," in *Conference on Learning for Dynamics & Control*, 2023.

[28] Y. Ma, Y. Liu, K. Qu, and M. Hutter, "Learning accurate whole-body throwing with high-frequency residual policy and pullback tube acceleration," *ArXiv*, 2025.

[29] X. Huang et al., "Creating a dynamic quadrupedal robotic goalkeeper with reinforcement learning," in *International Conference on Intelligent Robots and Systems (IROS)*, 2023.

[30] R. Hou, M. Zhu, H. Nam, G. I. Fernandez, and D. W. Hong, "Fast and robust localization for humanoid soccer robot via iterative landmark matching," *Arxiv*, 2025.

[31] Z. Xu et al., "Volleybots: A testbed for multi-drone volleyball game combining motion control and strategic play," *ArXiv*, 2025.

[32] Z. Chen, M. Ji, X. Cheng, X. Peng, X. B. Peng, and X. Wang, "Gmt: General motion tracking for humanoid whole-body control," *ArXiv*, 2025.

[33] T. He et al., "Asap: Aligning simulation and real-world physics for learning agile humanoid whole-body skills," in *Robotics: Science and Systems*, 2025.

[34] Q. Liao, T. E. Truong, X. Huang, G. Tevet, K. Sreenath, and C. K. Liu, "Beyondmimic: From motion tracking to versatile humanoid control via guided diffusion," *ArXiv*, 2025.

[35] A. Allshire et al., "Visual imitation enables contextual humanoid control," *ArXiv*, 2025.

[36] T. He et al., "Omnih2o: Universal and dexterous human-to-humanoid whole-body teleoperation and learning," in *Conference on Robot Learning*, 2024.

[37] W. Xie et al., "Kungfubot: Physics-based humanoid whole-body control for learning highly-dynamic skills," *ArXiv*, 2025.

[38] M. Ji et al., "Exbody2: Advanced expressive humanoid whole-body control," *ArXiv*, 2024.

[39] Y. Liu, B. Yang, L. Zhong, H. Wang, and L. Yi, "Mimicking-bench: A benchmark for generalizable humanoid-scene interaction learning via human mimicking," *ArXiv*, 2024.

[40] H. Xue et al., "Leverb: Humanoid whole-body control with latent vision-language instruction," *ArXiv*, 2025.

[41] L. Yang et al., "Omniretarget: Interaction-preserving data generation for humanoid whole-body loco-manipulation and scene interaction," *ArXiv*, 2025.

[42] S. Yin, Y. Ze, H.-X. Yu, C. K. Liu, and J. Wu, "Visualmimic: Visual humanoid loco-manipulation via motion tracking and generation," *ArXiv*, 2025.

[43] H. Weng et al., "Hdmi: Learning interactive humanoid whole-body control from human videos," *ArXiv*, 2025.

[44] S. Lin, G. Qiao, Y. Tai, A. Li, K. Jia, and G. Liu, "Hwc-loco: A hierarchical whole-body control approach to robust humanoid locomotion," *ArXiv*, 2025.

[45] L. Ma et al., "Styleloco: Generative adversarial distillation for natural humanoid robot locomotion," *ArXiv*, 2025.

[46] L. Pan et al., "Tokenhsi: Unified synthesis of physical human-scene interactions through task tokenization," in *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.

[47] Y. Wang et al., "Skillmimic: Learning basketball interaction skills from demonstrations," in *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.

[48] H. Sakoe and S. Chiba, "Dynamic programming algorithm optimization for spoken word recognition," *IEEE transactions on acoustics, speech, and signal processing*, 2003.